DUOC UC - Escuela de informática y telecomunicaciones

Programación para la Ciencia de Datos

Entrega 1

Nombres integrantes: Gino Andrades Medina, Yaii Selti Ramos, Miguel Villarroel Vergara

Asignatura: programación para la ciencia de datos

Docente: Jazna Patricia Meza HIdalgo

-

Índice

1. Resumen Ejecutivo

- 1.1. Propósito
- 1.2. Resultados claves

2. Análisis Exploratorio de Datos

- 2.1. Caracterización del Dataset de Clientes
- 2.2. Análisis Estadístico y Distribución de Ingresos
- 2.3. Resumen estadístico y visualización de hallazgos

3. Metodología de Limpieza de Datos

- 3.1. Tratamiento de Clientes con Ingreso Mensual Cero
- 3.2. Gestión de Valores Nulos e Inconsistencias en el Perfil de Cliente
- 3.3. Validación de la Integridad de los Datos de Salida

4. Metodología de Transformación e Ingeniería de Características

- 4.1. Codificación y Normalización de Variables
- 4.2. Ingeniería de Características (Feature Engineering)
- 4.3. Implementación de Pipelines de Procesamiento

5. Análisis de Resultados y Validación

- 5.1 Integridad y Calidad del Dataset Final
- 5.2 Generación de Valor Predictivo

6. Conclusiones y Recomendaciones

- 6.1 Impacto de la Transformación en la Estrategia de Retención
- 6.2 Superación de Desafíos Técnicos y Escalabilidad

1. Resumen ejecutivo

1.1 Propósito

- El objetivo principal de este trabajo es procesar y optimizar una base de datos de 20,400 clientes para abordar el problema del abandono del servicio. Se busca transformar la información original en un formato estructurado y de alta calidad que permita identificar con precisión los factores que influyen en la salida de los usuarios.

  Para cumplir con este propósito, es necesario estandarizar 22 variables distintas, que incluyen datos demográficos, financieros y de comportamiento. La meta es asegurar que toda la información sea coherente, eliminando errores y preparando el conjunto de datos para que pueda ser analizado.

1.2 Resultados claves

Tras la ejecución del plan de limpieza y transformación sobre los registros, se obtuvieron los siguientes resultados:

- **Limpieza de la Base de Datos:** Se eliminaron con éxito 400 registros duplicados que afectan la precisión de la información y podrían haber generado conclusiones erróneas.
- **Corrección de Inconsistencias:** Se gestionaron más de 1,000 vacíos de información en campos críticos como el ingreso mensual y el puntaje crediticio, utilizando métodos de relleno basados en el tipo de plan del cliente para mantener la lógica del negocio.
- **Ajuste de Errores de Registro:** Se detectaron y corrigieron montos negativos en deudas e ingresos, además de controlar valores extremos como outliers, que distorsionaba los promedios y las estadísticas generales.
- **Estandarización y Formato:** Se transformaron todas las categorías de texto (como región, género y tipo de plan) a formatos numéricos y se ajustaron las escalas de las variables de dinero, permitiendo que todos los datos sean comparables entre sí.
- **Automatización del Proceso:** Se consolidó un sistema automático (Pipeline) que ejecuta toda la secuencia de limpieza y preparación en un solo paso, lo que garantiza que el proceso sea reproducible.

2. Análisis Exploratorio de Datos

2.1. Caracterización del Dataset de Clientes

La base de datos analizada contiene información de 20,400 clientes y se compone de 22 variables:

```
# Cantidad de observaciones y columnas
data.shape
```

```
(20400, 22)
```

- Datos de Identificación y Perfil: Incluye el ID del cliente, fecha de registro, edad, género, región y estado civil.
- Datos Financieros: Contiene el ingreso mensual, gasto mensual, deuda total y el score crediticio.
- Datos de Comportamiento y Servicio: Registra la antigüedad, frecuencia de compra, días desde la última compra, uso de la aplicación móvil, tipo de plan contratado y si el cliente ha abandonado el servicio.

2.2. Análisis Estadístico y Distribución de Ingresos

Se realizó una observación de calidad sobre los datos crudos, detectando hallazgos que comprometen la fiabilidad del análisis si no son tratados:

- **Valores Nulos**: Se identificó una carencia de datos significativa en las variables financieras. Tanto *ingreso_mensual* como *score_crediticio* presentan **1,021 valores faltantes o nulos**, mientras que *gasto_mensual* tiene **1,025 también 1,025 nulos**.
- **Registros Duplicados**: Se detectaron **400 registros idénticos** en la base de datos.
- **Inconsistencias Lógicas**: Se hallaron valores negativos en campos que representan montos absolutos, como *ingreso_mensual, gasto_mensual y deuda_total,* lo cual indica errores en el proceso de captura de información.

-

2.3. Resumen estadístico y visualización de hallazgos

En el análisis de los datos como en histogramas no permiten visualizar y diagnosticar el comportamiento de los clientes a través de la información recopilada.

Se observa una alta concentración de usuarios en el rango de $600.000 a $1.000.000 aprox. Sin embargo, el gráfico revela un sesgo ligeramente pronunciado hacia la derecha debido a ingresos excepcionalmente altos y, de manera crítica, la presencia de valores negativos. Estos registros bajo cero confirman inconsistencias que requieren una corrección necesaria, ya que representan errores técnicos.

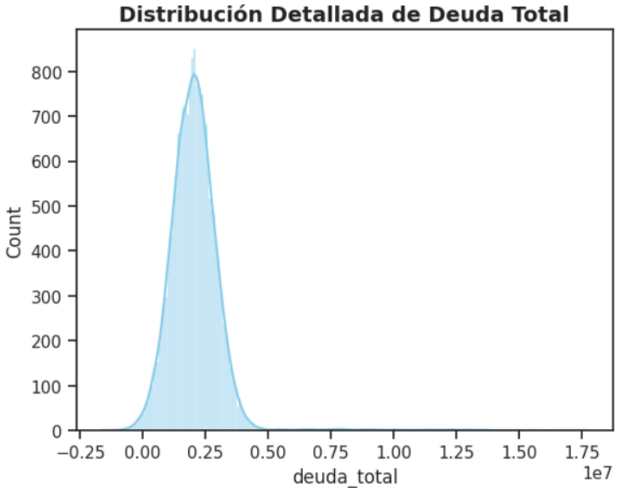

Complementariamente el análisis de valores atípicos mediante diagramas de caja evidencia una gran inestabilidad en las variables de monto. Las columnas de *deuda_total*, *ingreso_mensual* y *gasto_mensual* presentan una densidad masiva de valores extremos que se alejan de la mediana del grupo. Por otro lado, los atributos demográficos como la edad y la antigüedad_meses muestran un comportamiento mucho más uniforme.

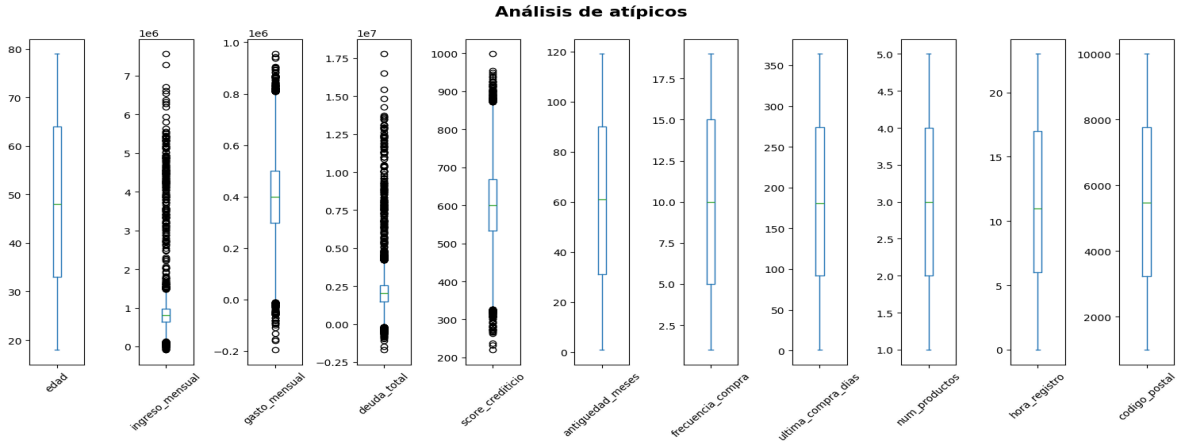

3. Metodología de Transformación

Esta sección describe las decisiones técnicas tomadas, fundamentadas en las mejores prácticas de la Ciencia de Datos.

3.1 Fase de Limpieza

El proceso de limpieza se diseñó bajo un enfoque de Pipeline de Producción, lo que garantiza que las reglas de transformación sean consistentes y replicables tanto para el set de entrenamiento como para nuevos datos.

A. Integridad de la Base de Datos

- **Remoción de Duplicados:** Se aplicó una limpieza inicial mediante *drop_duplicates()* para asegurar la unicidad de las observaciones. Este paso es crítico para evitar el sesgo por repetición de registros, lo cual podría inducir un sobreajuste (overfitting) donde el modelo memoriza filas idénticas en lugar de aprender patrones generales.

Funcion importante para Eliminar los duplicados

```
def eliminar_duplicados(X):
  return X.drop_duplicates()
```

- **Gestión de Variables irrelevantes:** Se procedió a la eliminación de columnas de identificación (como *id_cliente*) y variables sociodemográficas sin varianza significativa para el abandono, optimizando la eficiencia computacional del proceso.

```
# Muestra las medidas estadísticas, descartando la
data.drop(columns=['id_cliente']).describe()
```

-

B. Tratamiento de Inconsistencias (Negativos a Nulos)

Se implementó un transformador personalizado denominado **NegativeToNull**.

- Justificación: Variables financieras como *ingreso_mensual, gasto_mensual y score_crediticio* no pueden poseer valores negativos bajo ninguna lógica de negocio.
- Técnica: En lugar de eliminar estos registros, se transformaron en valores faltantes (NaN) para permitir que la fase de imputación posterior recupere la información basándose en el comportamiento de clientes similares.

C. Estrategia de Imputación Segmentada (Grouped Imputer)

A diferencia de una imputación simple, se utilizó la clase **GroupedImputer** para llenar vacíos de información de forma inteligente.

```python
class GroupedImputer(BaseEstimator, TransformerMixin):
    def __init__(self, group_col='tipo_plan', strategy='median'):
        self.group_col = group_col
        self.strategy = strategy
        self.stats_ = {}
        self.impute_cols = None
        self.input_columns_ = None

    def fit(self, X, y=None):
        X_df = pd.DataFrame(X)
        self.input_columns_ = pd.DataFrame(X).columns.tolist()

        self.impute_cols = X_df.select_dtypes(include=np.number).columns.drop(self.group_col, errors='ignore').tolist()

        if self.impute_cols:
            if self.strategy == 'median':
                self.stats_ = X_df.groupby(self.group_col)[self.impute_cols].median().to_dict()
            else:
                self.stats_ = X_df.groupby(self.group_col)[self.impute_cols].mean().to_dict()
        return self

    def transform(self, X):
        X_transformed = X.copy()
        if self.impute_cols:
            for col in self.impute_cols:
                if X_transformed[col].isnull().any():
                    imputation_map = self.stats_.get(col, {})
                    mapped_values = X_transformed[self.group_col].map(imputation_map)
                    X_transformed[col] = X_transformed[col].fillna(mapped_values)

                    # Si aun quedan Nulos los imputamos con una estadística global
                    if X_transformed[col].isnull().any():
                        global_stat = X[col].median() if self.strategy == 'median' else X[col].mean()
                        X_transformed[col] = X_transformed[col].fillna(global_stat)

        return X_transformed

    def get_feature_names_out(self, input_features=None):
        if input_features is not None:
            return np.array(input_features)
        return np.array(self.input_columns_)
```

- **Segmentación por tipo_plan:** Se utilizó el nivel del plan del cliente como variable de agrupación, asumiendo que el comportamiento financiero de un usuario "Premium" difiere del de un usuario "Básico".
- **Uso de la Mediana:** Para ingresos y gastos, se optó por la mediana ya que es una medida de tendencia central robusta ante valores atípicos, a diferencia de la media que podría verse distorsionada por ingresos extremadamente altos.
- **Uso de la Media:** En el caso del score_crediticio, se utilizó el promedio del segmento para mantener la estabilidad estadística del puntaje dentro de cada categoría de plan.

-

D. Tratamiento de Valores Atípicos (Winsorización)

Para estabilizar la varianza de los datos numéricos, se aplicó la técnica de Winsorización a través de un transformador Winsorizer.

- Lógica: En lugar de eliminar los outliers (valores extremos), se "capearon" o limitaron a los percentiles 5 y 95 (limits=(0.05, 0.05)). Esto permite conservar la observación en el dataset pero reduce el impacto negativo que los valores erráticos tienen sobre el aprendizaje del modelo.

3.2 Arquitectura del Pipeline de Limpieza

Toda la lógica anterior fue encapsulada en un `ColumnTransformer`, permitiendo un tratamiento diferenciado por grupos de variables:

Grupo de Variable	Pipeline Aplicado	Técnica de Imputación	Transformación Adicional
Financieras	pipeline_ingreso_gasto	Mediana por Plan	Winsorización (5%)
Crediticias	pipeline_score	Media por Plan	Winsorización (5%)
Comportamiento	pipeline_comportamiento	Mediana Global	Sin recorte de extremos
Cualitativas	cat	Moda (Más frecuente)	Codificación posterior

-

4. Metodología de Transformación e Ingeniería de Características

Una vez hecha la limpieza de la base de datos, se procedió a una etapa de transformación. El objetivo fue doble: primero, adaptar los datos para que sean interpretables y, segundo, crear nuevas métricas que capturen de mejor manera el comportamiento del cliente frente al riesgo de abandono.

4.1. Codificación y Normalización de Variables:

- **Variables Categóricas:** uso_app fue codificada con OneHotEncoder para su uso en el modelo, evitando jerarquías artificiales. tipo_plan se usó para la imputación agrupada, pero no para codificación directa en el modelo.
- **Escalamiento Numérico:** Todas las variables numéricas se estandarizaron (StandardScaler) para asegurar que contribuyen equitativamente al modelo, sin que ninguna domine por su magnitud.

4.2. Ingeniería de Características (Feature Engineering)

Para complementar la información disponible en el conjunto de datos, se desarrollaron cinco nuevas variables clave. Estos indicadores proporcionan una comprensión más profunda del comportamiento financiero y la lealtad de los clientes:

- **Ratio de Deuda:** Muestra la proporción de la deuda total de un cliente respecto a su ingreso mensual, ayudando a identificar situaciones de posible sobreendeudamiento.
- **Ratio de Gasto:** Indica qué parte del ingreso mensual del cliente se destina al servicio, revelando la importancia relativa de este gasto en su economía.
- **Índice de Lealtad:** Combina la antigüedad del cliente con su frecuencia de compra, sirviendo para reconocer a los clientes más fieles y valiosos.
- **Riesgo por Inactividad:** Evalúa la probabilidad de abandono al considerar el tiempo transcurrido desde la última compra en relación con el índice de lealtad del cliente. Clientes leales con inactividad reciente generan una alerta.

4.3. Implementación de Pipelines de Procesamiento

Todo este complejo flujo se consolidó en un **Pipeline de Limpieza y Transformación**. Esta arquitectura automática integra desde la eliminación de duplicados hasta la generación de las nuevas variables mencionadas.

La principal ventaja de este enfoque es la **reproducibilidad**: el pipeline permite que cualquier nuevo set de datos de clientes pase por exactamente el mismo proceso de manera automática, eliminando el error humano y asegurando que los 20,400 registros actuales y los futuros mantengan la misma estructura de calidad.

-

5. Análisis de Resultados y Validación

5.1 Integridad y Calidad del Dataset Final

Tras la ejecución del flujo de procesamiento, se obtuvo una base de datos de 20.000 registros únicos y 16 variables finales totalmente depuradas. La eliminación de los 400 duplicados y la corrección de valores negativos garantizan que el análisis de abandono se realice sobre una base de datos con integridad del 100%, eliminando sesgos que podrían comprometer las decisiones estratégicas de retención.

5.2 Generación de Valor Predictivo

La ingeniería de características permitió integrar indicadores clave como el Índice de Lealtad. Estas métricas transforman datos aislados en herramientas de diagnóstico financiero que identifican no solo el síntoma del abandono, sino las causas raíz relacionadas con el sobreendeudamiento y la inactividad del usuario, facilitando una segmentación precisa para el negocio.

```
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 16 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   edad                    20000 non-null  float64
 1   ingreso_mensual         20000 non-null  float64
 2   gasto_mensual           20000 non-null  float64
 3   score_crediticio        20000 non-null  float64
 4   deuda_total             20000 non-null  float64
 5   antiguedad_meses        20000 non-null  float64
 6   frecuencia_compra       20000 non-null  float64
 7   ultima_compra_dias      20000 non-null  float64
 8   ratio_deuda             20000 non-null  float64
 9   ratio_gasto             20000 non-null  float64
 10  indice_lealtad          20000 non-null  float64
 11  riesgo_por_inactividad  20000 non-null  float64
 12  uso_app_Alto            20000 non-null  float64
 13  uso_app_Bajo            20000 non-null  float64
 14  uso_app_Medio           20000 non-null  float64
 15  target__abandono        20000 non-null  float64
dtypes: float64(16)
```

-

6. Conclusiones y Recomendaciones

6.1 Impacto de la Transformación en la Estrategia de Retención

El proceso de manipulación de datos logró convertir un dataset crudo con inconsistencias críticas en un activo estratégico de **20.000 registros validados**. La creación de indicadores como el **Ratio de Deuda** y el **Índice de Lealtad** permite a la empresa pasar de una visión descriptiva a una analítica, proporcionando las herramientas necesarias para segmentar a los clientes con riesgo real de abandono y optimizar los recursos de retención basándose en evidencia financiera sólida.

6.2 Superación de Desafíos Técnicos y Escalabilidad

Se resolvieron desafíos complejos de integridad mediante el uso de **Pipelines automatizados**, garantizando que el tratamiento de valores atípicos (outliers) y la imputación de nulos no alteren la realidad estadística de la muestra. Como próximo paso para la fase de **Modelado Predictivo**, se recomienda la implementación de algoritmos de clasificación (como Random Forest o XGBoost) utilizando las 16 variables finales ya procesadas, asegurando así una transición fluida hacia la predicción automatizada del Churn.